

Аналитический отчет по курсовой работе

Введение

Цель данной работы - на основании предоставленных данных от химиков построить модели машинного обучения для предсказания значений *IC50*, *CC50* и *SI*, позволяющих оценивать эффективность химических соединений.

В рамках работы решаются задачи регрессии для предсказания значений *IC50*, *CC50* и *SI*, а также задачи классификации для определения превышения медианных значений этих показателей и порога $SI > 8$.

Описание данных

Датасет представляет собой совокупность химических дескрипторов - числовых значений, описывающих свойства молекул химических соединений.

Для каждого соединения определены целевые переменные:

- **IC50** (Half Maximal Inhibitory Concentration) - концентрация вещества, при которой достигается 50% ингибирования биологического процесса.
- **CC50** (Half Maximal Cytotoxic Concentration) - концентрация вещества, при которой погибает 50% клеток.
- **SI** (Selectivity Index) - индекс селективности, отношение *CC50* к *IC50*.

Разведочный анализ данных

Структура данных:

- Размерность датасета: **1001** строк, **213** столбцов.
- Все данные представлены в числовом формате.

Качество данных:

- Обнаружено константных признаков: **18**.
- Обнаружено дублирующихся строк: **32**.
- Доля пропущенных значений: **3.6 %** от всех значений.

Очистка данных:

- Удалены константные признаки и дублирующиеся строки.
- Пропуски заполнены медианными значениями.

Анализ целевых переменных:

- Были построены гистограммы и boxplot для *IC50*, *CC50* и *SI*.
- Распределения целевых переменных оказались скошенными вправо. Применение логарифмического преобразования позволило снизить асимметрию, распределения стали ближе к нормальным.

Анализ признаков:

- Признаки имеют разные масштабы значений.
- Сильных связей с целевыми переменными не выявлено (корреляция не превышает **0.9** ни для одного признака).
- Обнаружена высокая корреляция между частью признаков, включая дублирующие пары (корреляция равна или близка к **1.0**).

Подготовка данных:

- Обработка выбросов не проводилась, так как это может привести к потере важной информации о редких, но значимых химических соединениях.
- Признаки с попарной корреляцией выше **0.99** были удалены, так как они являются избыточными и не несут дополнительной информации.
- Добавлены логарифмированные значения целевых переменных.
- В соответствии с условием задачи для каждой целевой переменной были созданы бинарные признаки.
- Итоговый набор признаков и целевые переменные были сохранены для дальнейшего построения моделей.

Обучение моделей

Используемые модели

Для задач регрессии:

- ***LinearRegression*** - в качестве baseline-модели.
- ***RandomForestRegressor*** - ансамблевая модель на основе деревьев решений.
- ***CatBoostRegressor*** - модель градиентного бустинга.

Для задач классификации:

- ***LogisticRegression*** - в качестве baseline-модели.
- ***RandomForestClassifier*** - ансамблевая модель на основе деревьев решений.
- ***CatBoostClassifier*** - модель градиентного бустинга.

Линейные модели использовались как базовые решения для оценки минимального достижимого качества.

RandomForest и *CatBoost* были выбраны как более гибкие модели, способные учитывать нелинейные зависимости между химическими дескрипторами и целевыми

переменными.

Для *LogisticRegression* признаки были дополнительно масштабированы с помощью **StandardScaler**, так как линейные модели чувствительны к масштабу признаков. Для *RandomForest* и *CatBoost* масштабирование не требовалось.

Подбор гиперпараметров

Для каждой модели был выполнен подбор гиперпараметров с использованием **GridSearchCV** и кросс-валидации (**cv=3**).

Для регрессии в качестве метрики оптимизации использовалась **neg_root_mean_squared_error**, для классификации - **roc_auc**.

После подбора лучшая модель проверялась на отложенной тестовой выборке (20% данных).

Метрики качества

Для задач регрессии:

- **MAE** (Mean Absolute Error) - средняя абсолютная ошибка прогноза.
- **RMSE** (Root Mean Squared Error) - корень из среднеквадратичной ошибки (сильнее штрафует крупные ошибки).
- **R²** (коэффициент детерминации) - доля дисперсии целевой переменной, объясненная моделью.

Для задач классификации:

- **F1-score** - гармоническое среднее точности (*precision*) и полноты (*recall*), показывает баланс между правильно найденными положительными объектами и ложными срабатываниями.
- **ROC-AUC** - площадь под ROC-кривой, показывает общую способность модели различать классы.

Сравнение результатов

Регрессия:

Целевая переменная	Лучшая модель	MAE	RMSE	R ²
IC50	RandomForest / CatBoost	1.1 / 1.1	1.35 / 1.35	0.5 / 0.5
CC50	RandomForest / CatBoost	0.88 / 0.87	1.26 / 1.25	0.32 / 0.34
SI	CatBoost	0.93	1.29	0.26

Классификация:

Целевая переменная	Лучшая модель	F1	ROC-AUC
<i>IC50 > median</i>	<i>RandomForest / CatBoost</i>	0.74 / 0.72	0.82 / 0.83
<i>CC50 > median</i>	<i>RandomForest</i>	0.75	0.84
<i>SI > median</i>	<i>RandomForest / CatBoost</i>	0.62 / 0.62	0.7 / 0.69
<i>SI > 8</i>	<i>CatBoost</i>	0.56	0.76

Итог по обучению моделей

Лучшие результаты показали ансамблевые модели *RandomForest* и *CatBoost*, что подтверждает наличие нелинейных зависимостей между химическими дескрипторами и целевыми переменными.

Существенного доминирования одной модели над другой не наблюдается, поэтому обе можно считать сопоставимо эффективными для данной задачи.

Линейные модели стабильно уступают ансамблевым, что указывает на сложную структуру зависимости в данных.

Наиболее сложной задачей оказался прогноз *SI*. Это объясняется тем, что *SI* является производной величиной, зависящей от отношения *CC50* к *IC50*.

Рекомендации по продолжению исследования

Расширение датасета: увеличение объема экспериментальных данных позволит моделям лучше обобщаться и повысит устойчивость результатов, особенно для задач с низким R^2 .

Отбор признаков: использование *feature importance* моделей позволит выявить наиболее значимые дескрипторы и сократить размерность, что может улучшить качество и скорость обучения.

Расширение подбора гиперпараметров: текущий перебор ограничен небольшой сеткой значений. Применение *RandomizedSearchCV* с более широким диапазоном параметров может дать прирост качества.

Вывод

В ходе работы были построены модели регрессии и классификации для оценки эффективности химических соединений по показателям *IC50*, *CC50* и *SI*.

Полученные результаты показали, что ансамблевые модели *RandomForest* и *CatBoost* обеспечивают наилучшее качество предсказаний и могут быть использованы для практической оценки активности соединений.

Линейные модели выступают в роли базового уровня и демонстрируют ограниченную применимость для данной задачи из-за сложности и нелинейности зависимостей в данных.

В целом, построенные модели показывают удовлетворительное качество и могут быть использованы как вспомогательный инструмент для первичного отбора перспективных соединений, однако для повышения точности прогнозов требуется дальнейшая доработка подхода и расширение данных.